Московский государственный технический университет им. Н.Э. Баумана Кафедра «Системы обработки информации и управления»

Лабораторная работа №3 по дисциплине «Методы машинного обучения» на тему «Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных»

Выполнил: студент группы ИУ5-23М Наседкин И. А.

1. Лабораторная работа №3 по курсу ММО (Наседкин Игорь ИУ5-23М)

```
[0]: import numpy as np
     import pandas as pd
     import seaborn as sns
     import matplotlib.pyplot as plt
     %matplotlib inline
     sns.set(style="ticks")
[0]: #Возьмем дата-сет сведений о бронировании отелей
     data = pd.read csv('hotel bookings.csv', sep=",")
       https://www.kaggle.com/jessemostipak/hotel-booking-demand
[0]: # размер набора данных
     data.shape
[0]: (119390, 32)
[0]: # типы колонок
     data.dtypes
[0]: hotel
                                          object
     is canceled
                                           int64
     lead time
                                           int64
     arrival_date_year
                                           int64
     arrival_date_month
                                          object
     arrival date week number
                                           int64
     arrival date day of month
                                           int64
     stays_in_weekend_nights
                                           int64
     stays in week nights
                                           int64
     adults
                                           int64
     children
                                         float64
     babies
                                           int64
     meal
                                          object
     country
                                          object
     market_segment
                                          object
     distribution_channel
                                          object
     is repeated guest
                                           int64
     previous cancellations
                                           int64
     previous_bookings_not_canceled
                                           int64
     reserved_room_type
                                          object
     assigned_room_type
                                          object
     booking_changes
                                           int64
     deposit_type
                                          object
     agent
                                         float64
     company
                                         float64
     days_in_waiting_list
                                           int64
     customer type
                                          object
     adr
                                         float64
```

```
reservation status
                                          object
     reservation_status_date
                                          object
     dtype: object
[0]: # проверим есть ли пропущенные значения
     data.isnull().sum()
[0]: hotel
                                              0
     is canceled
                                              0
     lead time
                                              0
     arrival_date_year
                                              0
     arrival date month
                                              0
     arrival date week number
                                              0
     arrival date day of month
                                              0
     stays in weekend nights
                                              0
     stays_in_week_nights
                                              0
     adults
                                              0
     children
                                              4
     babies
                                              0
     meal
                                              0
                                            488
     country
     market segment
                                              0
     distribution channel
                                              0
                                              0
     is repeated guest
                                              0
     previous_cancellations
     previous_bookings_not_canceled
                                              0
                                              0
     reserved room type
     assigned_room_type
                                              0
                                              0
     booking_changes
     deposit type
                                              0
     agent
                                          16340
     company
                                        112593
     days_in_waiting_list
                                              0
     customer_type
                                              0
                                              0
     adr
     required_car_parking_spaces
                                              0
     total_of_special_requests
                                              0
     reservation_status
                                              0
     reservation status date
                                              0
     dtype: int64
[0]: # Первые 5 строк датасета
     data.head()
[0]:
               hotel is_canceled
                                      reservation_status 🛚
      →reservation_status_date
     0 Resort Hotel
                                 0
                                                 Check-Out
                                                                         ?
      →2015-07-01
```

int64

int64

required car parking spaces

total of special requests

```
0 ...
    1 Resort Hotel
                                             Check-Out
                                                                    ?
      →2015-07-01
    2 Resort Hotel
                               0 ...
                                             Check-Out
                                                                    ?
      →2015-07-02
    3 Resort Hotel
                                             Check-Out
                               0 ...
                                                                    ?
      →2015-07-02
                               0 ...
    4 Resort Hotel
                                             Check-Out
                                                                    ?
     →2015-07-03
    [5 rows x 32 columns]
[0]: total count = data.shape[0]
     print('Bcero cτροκ: {}'.format(total count))
    Всего строк: 119390
    2. Обработка пропусков в данных
[0]: # Удаление колонок, содержащих пустые значения
     data new 1 = data.dropna(axis=1, how='any')
     (data.shape, data_new_1.shape)
[0]: ((119390, 32), (119390, 28))
[0]: # Удаление строк, содержащих пустые значения
     data new 2 = data.dropna(axis=0, how='any')
     (data.shape, data new 2.shape)
[0]: ((119390, 32), (217, 32))
[0]: # Заполнение всех пропущенных значений нулями
    # В данном случае это некорректно, так как нулями заполняются в том
     ⊶числе категориальные колонки
    data new 3 = data.fillna(0)
    data new 3.head()
[0]:
              hotel is_canceled ... reservation_status ?
     →reservation status date
    0 Resort Hotel
                                             Check-Out
                                                                    ?
                               0
     →2015-07-01
    1 Resort Hotel
                               0 ...
                                             Check-Out
                                                                    ?
     →2015-07-01
    2 Resort Hotel
                               0 ...
                                             Check-Out
                                                                    ?
      2015-07-02
    3 Resort Hotel
                              0 ...
                                             Check-Out
                                                                    ?
      2015-07-02
                               0 ...
    4 Resort Hotel
                                             Check-Out
                                                                    ?
```

2015-07-03

3. Импьютация

```
[0]: # Выберем числовые колонки с пропущенными значениями
# Цикл по колонкам датасета
num_cols = []
for col in data.columns:
# Количество пустых значений
temp_null_count = data[data[col].isnull()].shape[0]
dt = str(data[col].dtype)
if temp_null_count>0 and (dt=='float64' or dt=='int64'):
    num_cols.append(col)
    temp_perc = round((temp_null_count / total_count) * 100.0, 2)
    print('Колонка {}. Тип данных {}. Количество пустых значений
→{}, {}%.'.format(col, dt, temp_null_count, temp_perc))
```

Колонка children. Тип данных float64. Количество пустых значений 4, 0.0%. Колонка agent. Тип данных float64. Количество пустых значений 16340, 13. \rightarrow 69%.

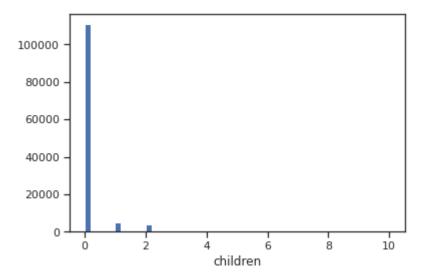
```
[0]: # Фильтр по колонкам с пропущенными значениями data_num = data[num_cols] data_num
```

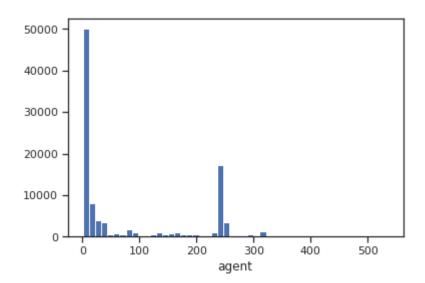
```
[0]:
             children agent company
                  0.0
                         NaN
     0
                                  NaN
     1
                  0.0
                         NaN
                                  NaN
     2
                  0.0
                         NaN
                                  NaN
     3
                  0.0 304.0
                                  NaN
     4
                  0.0 240.0
                                  NaN
                                  NaN
    119385
                  0.0 394.0
     119386
                  0.0
                         9.0
                                  NaN
                        9.0
                                  NaN
     119387
                  0.0
     119388
                  0.0
                        89.0
                                  NaN
                  0.0
                         9.0
     119389
                                  NaN
```

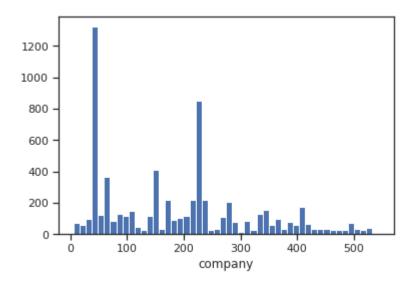
[119390 rows x 3 columns]

```
[0]: # Гистограмма по признакам
for col in data_num:
    plt.hist(data[col], 50)
    plt.xlabel(col)
    plt.show()
```

/usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py:839:
RuntimeWarning: invalid value encountered in greater_equal
 keep = (tmp_a >= first_edge)
/usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py:840:
RuntimeWarning: invalid value encountered in less_equal
 keep &= (tmp_a <= last_edge)</pre>







```
[0]: # Фильтр по пустым значениям поля agent data[data['agent'].isnull()]
```

```
hotel is_canceled ... reservation_status
[0]:
     reservation_status_date
                                      0 ...
             Resort Hotel
                                                      Check-Out
     2015-07-01
     1
             Resort Hotel
                                      0 ...
                                                      Check-Out
     2015-07-01
             Resort Hotel
                                      0 ...
                                                      Check-Out
     2015-07-02
             Resort Hotel
                                                      Check-Out
     2015-07-03
             Resort Hotel
                                                      Check-Out
     18
                                      0 ...
     2015-07-02
     119124
             City Hotel
                                                      Check-Out
                                      0 ...
     2017-08-30
     119151
               City Hotel
                                      0 ...
                                                      Check-Out
     2017-08-30
     119166
               City Hotel
                                                      Check-Out
                                      0 ...
     2017-08-31
     119215
               City Hotel
                                                      Check-Out
     2017-09-01
     119248
               City Hotel
                                      0 ...
                                                      Check-Out
     2017-09-01
```

[16340 rows x 32 columns]

```
[0]: # Запоминаем индексы строк с пустыми значениями flt_index = data[data['agent'].isnull()].index flt_index
```

```
[0]: Int64Index([ 0, 1, 2, 6, 18, 30,
                                                                    32,
                                                                           ?
      →42,
                    55,
                            56,
                119117, 119118, 119119, 119122, 119123, 119124, 119151,
      →119166,
                119215, 119248],
               dtype='int64', length=16340)
[0]: # Проверяем что выводятся нужные строки
     data[data.index.isin(flt_index)]
[0]:
                   hotel is canceled ... reservation status
    reservation_status_date
            Resort Hotel
                                    0 ...
                                                   Check-Out
    2015-07-01
            Resort Hotel
                                    0 ...
                                                   Check-Out
    2015-07-01
            Resort Hotel
                                    0 ...
                                                   Check-Out
    2015-07-02
            Resort Hotel
                                    0 ...
                                                   Check-Out
    2015-07-03
            Resort Hotel
                                    0 ...
                                                   Check-Out
    2015-07-02
    119124 City Hotel
                                                   Check-Out
                                    0 ...
    2017-08-30
    119151
              City Hotel
                                    0 ...
                                                   Check-Out
    2017-08-30
    119166
              City Hotel
                                    0 ...
                                                   Check-Out
    2017-08-31
                                    0 ...
    119215
             City Hotel
                                                   Check-Out
    2017-09-01
    119248
              City Hotel
                                    0 ...
                                                   Check-Out
    2017-09-01
     [16340 rows x 32 columns]
[0]: # фильтр по колонке
     data_num[data_num.index.isin(flt_index)]['agent']
[0]: 0
             NaN
    1
             NaN
     2
             NaN
     6
             NaN
    18
             NaN
    119124
             NaN
    119151
             NaN
```

```
119166
              NaN
     119215
              NaN
     119248
              NaN
     Name: agent, Length: 16340, dtype: float64
[0]: data num agent = data num[['agent']]
     data num agent.head()
[0]:
        agent
          NaN
     1
          NaN
     2
          NaN
     3 304.0
     4 240.0
[0]: from sklearn.impute import SimpleImputer
     from sklearn.impute import MissingIndicator
[0]: # Фильтр для проверки заполнения пустых значений
     indicator = MissingIndicator()
     mask missing values only = indicator.fit transform(data num agent)
     mask_missing_values_only
[0]: array([[ True],
            [True],
            [ True],
            [False],
            [False],
            [False]])
[0]: strategies=['mean', 'median', 'most_frequent']
[0]: def test num impute(strategy param):
         imp num = SimpleImputer(strategy=strategy param)
         data num imp = imp num.fit transform(data num agent)
         return data num imp[mask missing values only]
[0]: strategies[0], test_num_impute(strategies[0])
[0]: ('mean', array([86.69338185, 86.69338185, 86.69338185, ..., 86.69338185,
             86.69338185, 86.69338185]))
[0]: strategies[1], test_num_impute(strategies[1])
[0]: ('median', array([14., 14., 14., ..., 14., 14., 14.]))
[0]: strategies[2], test num impute(strategies[2])
[0]: ('most_frequent', array([9., 9., 9., ..., 9., 9., 9.]))
```

```
[0]: # Более сложная функция, которая позволяет задавать колонку и вид
      →импьютации
     def test num impute col(dataset, column, strategy param):
         temp_data = dataset[[column]]
         indicator = MissingIndicator()
         mask missing values only = indicator.fit transform(temp data)
         imp num = SimpleImputer(strategy=strategy param)
         data num imp = imp num.fit transform(temp data)
         filled data = data num imp[mask missing values only]
         return column, strategy param, filled data.size, filled data[0], ▶
      →filled data[filled data.size-1]
[0]: data[['company']].describe()
[0]:
                company
    count 6797.000000
    mean
            189.266735
     std
             131.655015
    min
               6.000000
    25%
              62.000000
    50%
            179.000000
    75%
             270.000000
             543.000000
    max
[0]: test_num_impute_col(data, 'company', strategies[0])
[0]: ('company', 'mean', 112593, 189.26673532440782, 189.26673532440782)
[0]: test_num_impute_col(data, 'company', strategies[1])
[0]: ('company', 'median', 112593, 179.0, 179.0)
[0]: test num impute col(data, 'company', strategies[2])
[0]: ('company', 'most_frequent', 112593, 40.0, 40.0)
```

4. Обработка пропусков в категориальных данных

```
[0]: # Выберем категориальные колонки с пропущенными значениями
# Цикл по колонкам датасета
cat_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0 and (dt=='object'):
```

```
cat cols.append(col)
              temp perc = round((temp null count / total count) * 100.0, 2)
              print('Колонка {}. Тип данных {}. Количество пустых значений№
       →{}, {}%.'.format(col, dt, temp null count, temp perc))
    Колонка country. Тип данных object. Количество пустых значений 488, 0.
      →41%.
[0]: cat_temp_data = data[['country']]
     cat_temp_data.head()
[0]:
       country
            PRT
     0
            PRT
     1
     2
            GBR
     3
           GBR
     4
           GBR
[0]: cat temp data['country'].unique()
[0]: array(['PRT', 'GBR', 'USA', 'ESP', 'IRL', 'FRA', nan, 'ROU', 'NOR', □
      →'OMN',
                    'POL',
                            'DEU',
             'ARG',
                                    'BEL',
                                            'CHE',
                                                   'CN', 'GRC', 'ITA',
             'DNK',
                    'RUS',
                            'SWE',
                                            'EST',
                                                           'BRA',
                                    'AUS',
                                                   'CZE',
                                                                   'FIN',
                                                                           'MOZ',
                                            'IND',
                                                   'CHN',
             'BWA',
                    'LUX',
                            'SVN',
                                    'ALB',
                                                           'MEX',
                                                                   'MAR',
                                                                           'UKR',
             'SMR',
                    'LVA',
                            'PRI',
                                            'CHL',
                                                           'BLR',
                                    'SRB',
                                                   'AUT',
                                                                   'LTU',
                                                                           'TUR'
             'ZAF',
                                            'ZMB',
                                                   'CPV',
                                                           'ZWE',
                    'AGO',
                            'ISR',
                                    'CYM',
                                                                   'DZA',
                                                                           'KOR',
                            'ARE',
                                            'JAM',
                                                           'HKG',
                    'HUN',
                                    'TUN',
                                                   'HRV',
             'CRI',
                                                                   'IRN',
                                                                           'GEO',
                    'GIB',
                            'URY',
                                    'JEY',
                                            'CAF',
                                                           'COL',
             'AND',
                                                   'CYP',
                                                                   'GGY',
                                                                           'KWT',
                                            'FJI',
                     'MDV',
                                                           'PAK',
             'NGA',
                            'VEN'
                                    'SVK',
                                                                   'IDN'
                                                   'KAZ',
                                                                           'LBN'
             'PHL',
                    'SEN',
                            'SYC',
                                            'BHR',
                                                   'NZL',
                                                           'THA',
                                    'AZE',
                                                                   'DOM',
                                                                           'MKD',
                    'ARM',
                                                           'BIH',
             'MYS',
                            'JPN',
                                    'LKA',
                                            'CUB',
                                                   'CMR',
                                                                   'MUS',
                                                                           'COM',
                                                           'SGP',
             'SUR',
                    'UGA',
                                    'CIV',
                                            'JOR',
                            'BGR',
                                                   'SYR',
                                                                   'BDI',
                                                                           'SAU',
                                            'PER',
             'VNM',
                    'PLW',
                            'OAT',
                                    'EGY',
                                                           'MWI',
                                                                   'ECU',
                                                   'MLT',
                                                                           'MDG',
                    'UZB',
                            'NPL',
                                    'BHS',
                                            'MAC',
                                                   'TGO',
                                                           'TWN',
                                                                   'DJI',
             'ISL',
                                                                           'STP',
             'KNA',
                    'ETH',
                                                   'KHM',
                                                           'MCO',
                            'IRQ',
                                    'HND',
                                            'RWA',
                                                                   'BGD',
                                                                           'IMN',
                    'NIC',
                                    'VGB',
                                            'TZA',
                                                           'GHA',
                            'BEN',
             'TJK',
                                                   'GAB',
                                                                   'TMP'
                                                                           'GLP'
                            'GNB',
             'KEN', 'LIE',
                                    'MNE',
                                            'UMI',
                                                   'MYT',
                                                           'FRO',
                                                                   'MMR',
                                                                           'PAN',
                   'LBY',
             'BFA',
                                                           'BRB',
                                                   'PRY',
                                                                   'ABW',
                            'MLI',
                                    'NAM',
                                            'BOL',
                                                                           'AIA',
                    'DMA',
             'SLV',
                            'PYF',
                                    'GUY',
                                            'LCA',
                                                   'ATA', 'GTM', 'ASM',
                                                                           'MRT',
             'NCL', 'KIR', 'SDN',
                                   'ATF', 'SLE', 'LAO'], dtype=object)
[0]: cat temp data[cat temp data['country'].isnull()].shape
[0]: (488, 1)
[0]: # Импьютация наиболее частыми значениями
     imp2 = SimpleImputer(missing values=np.nan, strategy='most frequent')
     data imp2 = imp2.fit transform(cat temp data)
     data imp2
```

```
[0]: array([['PRT'],
             ['PRT'],
             ['GBR'],
             ['DEU'],
             ['GBR'],
             ['DEU']], dtype=object)
[0]: # Пустые значения отсутствуют
     np.unique(data imp2)
                     'AGO',
                             'AIA',
                                     'ALB',
                                             'AND',
                                                     'ARE',
                                                             'ARG',
                                                                     'ARM',
[0]: array(['ABW',
                                                                             'ASM',
             'ATA',
                     'ATF',
                             'AUS',
                                     'AUT',
                                             'AZE',
                                                             'BEL',
                                                                     'BEN',
                                                     'BDI',
                                                                             'BFA',
                     'BGR',
             'BGD',
                             'BHR',
                                     'BHS',
                                             'BIH',
                                                     'BLR',
                                                             'BOL',
                                                                     'BRA',
                                                                             'BRB',
                     'CAF',
                                             'CHN',
                                                             'CMR',
             'BWA',
                             'CHE'
                                     'CHL'
                                                     'CIV',
                                                                     'CN',
                                                                           'COL',
                                                     'CYP',
                     'CPV',
                             'CRI',
                                                             'CZE',
                                                                     'DEU',
             'COM',
                                     'CUB',
                                             'CYM',
                                                                             'DJI',
                                                             'ESP',
                                             'ECU',
                                                     'EGY',
             'DMA',
                     'DNK',
                             'DOM',
                                     'DZA',
                                                                     'EST',
                                                                             'ETH',
                                                     'GBR',
             'FIN',
                     'FJI',
                                     'FRO',
                                                             'GEO',
                                             'GAB',
                                                                     'GGY',
                             'FRA',
                                                                             'GHA',
             'GIB',
                     'GLP',
                                             'GTM',
                                                             'HKG',
                             'GNB'
                                     'GRC',
                                                     'GUY',
                                                                     'HND'
                                                                             'HRV'
                                             'IRL',
                     'IDN',
                             'IMN',
                                     'IND',
                                                     'IRN',
             'HUN',
                                                             'IRQ',
                                                                     'ISL',
                                                                             'ISR',
             'ITA',
                     'JAM',
                             'JEY',
                                     'JOR',
                                             'JPN',
                                                     'KAZ',
                                                             'KEN',
                                                                     'KHM',
                                                                             'KIR',
                     'KOR',
                                             'LBN',
             'KNA',
                             'KWT',
                                     'LAO',
                                                     'LBY',
                                                             'LCA',
                                                                     'LIE',
                                                                             'LKA'
                                             'MAR',
             'LTU',
                     'LUX',
                                     'MAC',
                                                             'MDG',
                                                                     'MDV',
                             'LVA',
                                                     'MCO',
                                                                             'MEX',
                                                                     'MUS',
             'MKD',
                     'MLI',
                             'MLT',
                                     'MMR',
                                             'MNE',
                                                     'MOZ',
                                                             'MRT',
                                                                             'MWI'
                                                     'NIC',
             'MYS',
                     'MYT',
                             'NAM',
                                                             'NLD',
                                                                     'NOR',
                                     'NCL',
                                             'NGA',
                                                                             'NPL'
                     'OMN',
                                     'PAN',
                                                             'PLW',
                                                                     'POL',
             'NZL',
                             'PAK',
                                             'PER',
                                                     'PHL',
                                                                             'PRI',
                             'PYF',
                                     'QAT',
             'PRT',
                     'PRY',
                                             'ROU',
                                                     'RUS',
                                                             'RWA',
                                                                     'SAU',
                                                                             'SDN',
                                                             'STP',
                             'SLE',
             'SEN',
                     'SGP',
                                     'SLV',
                                             'SMR',
                                                     'SRB',
                                                                     'SUR',
                                                                             'SVK',
                     'SWE',
                             'SYC',
                                     'SYR',
                                             'TGO',
                                                             'TJK',
                                                                     'TMP',
             'SVN',
                                                     'THA',
                                                                             'TUN',
             'TUR',
                                             'UKR',
                                     'UGA',
                                                            'URY', 'USA',
                     'TWN',
                             'TZA',
                                                    'UMI',
                                                                             'UZB',
             'VEN', 'VGB', 'VNM', 'ZAF', 'ZMB', 'ZWE'], dtype=object)
[0]: # Импьютация константой
     imp3 = SimpleImputer(missing values=np.nan, strategy='constant',P
       →fill value='!!!')
     data imp3 = imp3.fit transform(cat temp data)
     data imp3
[0]: array([['PRT'],
             ['PRT'],
             ['GBR'],
             ر ...
             ['DEU'],
             ['GBR'],
             ['DEU']], dtype=object)
[0]: np.unique(data imp3)
[0]: array(['!!!', 'ABW', 'AGO', 'AIA', 'ALB',
                                                     'AND',
                                                             'ARE',
                                                                     'ARG',
                                                                             'ARM',
             'ASM', 'ATA', 'ATF', 'AUS', 'AUT', 'AZE', 'BDI', 'BEL',
                                                                             'BEN',
             'BFA', 'BGD', 'BGR', 'BHR', 'BHS', 'BIH', 'BLR', 'BOL',
```

```
'CHE',
                                                                       'CMR',
              'BRB',
                      'BWA',
                              'CAF',
                                               'CHL',
                                                       'CHN',
                                                               'CIV',
                                                                                'CN',
                                                               'CYP',
              'COL',
                      'COM',
                              'CPV',
                                               'CUB',
                                                                        'CZE',
                                                       'CYM',
                                       'CRI',
                                                                                'DEU',
                                                               'EGY',
              'DJI',
                      'DMA',
                              'DNK'
                                       'DOM',
                                               'DZA',
                                                       'ECU',
                                                                        'ESP',
                                                                                'EST'
                                               'FRO',
                                       'FRA',
                                                       'GAB',
              'ETH',
                      'FIN',
                              'FJI',
                                                               'GBR',
                                                                        'GEO',
                                                                                'GGY',
                      'GIB',
              'GHA',
                              'GLP',
                                       'GNB',
                                               'GRC',
                                                       'GTM',
                                                               'GUY',
                                                                        'HKG',
                                                                                'HND',
              'HRV',
                      'HUN',
                                               'IND',
                                                       'IRL',
                                                               'IRN',
                              'IDN',
                                       'IMN',
                                                                        'IRQ',
                                                                                'ISL',
                      'ITA',
                                                               'KAZ',
              'ISR',
                              'JAM'
                                       'JEY',
                                               'JOR',
                                                       'JPN',
                                                                        'KEN',
                                                                                'KHM',
                                       'KWT',
                                               'LAO',
              'KIR',
                      'KNA',
                              'KOR',
                                                       'LBN',
                                                               'LBY',
                                                                        'LCA',
                                                                                'LIE'
                                                               'MCO',
                                                                        'MDG',
              'LKA',
                      'LTU',
                              'LUX',
                                               'MAC',
                                                       'MAR',
                                       'LVA',
                                                                                'MDV'.
                                               'MMR',
                                                               'MOZ',
              'MEX',
                      'MKD',
                              'MLI'
                                       'MLT'
                                                       'MNE',
                                                                        'MRT'
                                                                                'MUS'
                                               'NCL',
              'MWI',
                      'MYS',
                                       'NAM',
                                                               'NIC',
                                                                        'NLD',
                              'MYT',
                                                       'NGA',
                                                                                'NOR',
                              'OMN',
              'NPL',
                      'NZL',
                                       'PAK',
                                               'PAN',
                                                       'PER',
                                                               'PHL',
                                                                        'PLW',
                                                                                'POL',
                      'PRT',
                                                               'RUS',
                                                                        'RWA',
                              'PRY'
                                       'PYF',
                                               'QAT',
                                                       'ROU',
              'PRI',
                                                                                'SAU',
              'SDN',
                                               'SLV',
                      'SEN',
                              'SGP',
                                       'SLE',
                                                               'SRB',
                                                                        'STP',
                                                       'SMR',
                                                                                'SUR',
              'SVK',
                                       'SYC',
                                                                        'TJK',
                      'SVN',
                              'SWE',
                                               'SYR',
                                                       'TGO',
                                                               'THA',
                                                                                'TMP'
              'TUN',
                     'TUR',
                              'TWN',
                                               'UGA',
                                                       'UKR',
                                       'TZA',
                                                               'UMI', 'URY',
                                               'ZAF', 'ZMB', 'ZWE'], dtype=object)
              'UZB', 'VEN', 'VGB', 'VNM',
[0]: data imp3[data imp3=='!!!'].size
[0]: 488
```

5. Кодирование категориальных признаков

```
[0]: cat enc = pd.DataFrame({'c1':data imp2.T[0]})
     cat_enc
[0]:
               c1
              PRT
     0
     1
              PRT
     2
              GBR
     3
              GBR
     4
              GBR
     119385
              BEL
     119386
              FRA
     119387
              DEU
     119388
              GBR
     119389
              DEU
     [119390 rows x 1 columns]
```

6. Кодирование целочисленными значениями

```
[0]: from sklearn.preprocessing import LabelEncoder, OneHotEncoder
```

```
[0]: le = LabelEncoder()
     cat_enc_le = le.fit_transform(cat_enc['c1'])
[0]: cat enc['c1'].unique()
                                                              'ROU',
                     'GBR',
[0]: array(['PRT',
                             'USA',
                                      'ESP',
                                              'IRL',
                                                      'FRA',
                                                                      'NOR',
                     'POL',
                                                      'CN', 'GRC', 'ITA', 'NLD',
                              'DEU',
                                      'BEL',
                                              'CHE',
              'ARG',
                              'SWE',
                                      'AUS',
              'DNK',
                     'RUS',
                                              'EST',
                                                              'BRA',
                                                                      'FIN',
                                                      'CZE',
                                                                              'MOZ',
                                              'IND',
                     'LUX',
                              'SVN',
                                      'ALB',
                                                      'CHN',
                                                              'MEX',
                                                                      'MAR',
              'BWA',
                                                                              'UKR'
                                                                      'LTU',
             'SMR',
                     'LVA',
                              'PRI',
                                      'SRB',
                                              'CHL',
                                                      'AUT',
                                                              'BLR',
                                                                              'TUR',
                                              'ZMB',
                                                              'ZWE',
              'ZAF',
                     'AGO',
                              'ISR'
                                      'CYM',
                                                      'CPV',
                                                                      'DZA'
                                                                              'KOR'
                              'ARE',
                                              'JAM',
                                                      'HRV',
                                                              'HKG',
             'CRI',
                     'HUN',
                                      'TUN',
                                                                      'IRN',
                                                                              'GEO',
                     'GIB',
                                      'JEY',
                                              'CAF',
                                                      'CYP',
                                                              'COL',
              'AND',
                              'URY',
                                                                      'GGY',
                                                                              'KWT'
                     'MDV',
                                              'FJI',
                                                              'PAK',
                              'VEN',
                                      'SVK',
                                                      'KAZ',
                                                                      'IDN',
              'NGA',
                                                                              'LBN',
              'PHL',
                                                      'NZL',
                     'SEN',
                              'SYC',
                                      'AZE',
                                                              'THA',
                                                                      'DOM',
                                              'BHR',
                                                                              'MKD',
                              'JPN',
             'MYS',
                     'ARM',
                                      'LKA',
                                              'CUB',
                                                      'CMR',
                                                              'BIH',
                                                                      'MUS',
                                                                              'COM',
                                                              'SGP',
             'SUR',
                              'BGR',
                                      'CIV',
                                              'JOR',
                                                      'SYR',
                                                                      'BDI',
                     'UGA',
                                                                              'SAU',
              'VNM',
                                              'PER',
                     'PLW',
                              'QAT'
                                      'EGY',
                                                      'MLT',
                                                              'MWI',
                                                                      'ECU'
                                                                              'MDG'
              'ISL',
                                              'MAC',
                                                              'TWN',
                                                                      'DJI',
                     'UZB',
                              'NPL',
                                      'BHS',
                                                      'TGO',
                                                                              'STP'
                                                                      'BGD',
              'KNA',
                     'ETH',
                                      'HND',
                                                      'KHM',
                              'IRQ',
                                              'RWA',
                                                              'MCO',
                                                                              'IMN',
                     'NIC',
              'TJK',
                              'BEN',
                                      'VGB',
                                              'TZA',
                                                      'GAB',
                                                              'GHA',
                                                                      'TMP',
                                                                              'GLP'
                                              'UMI',
                     'LIE',
                              'GNB',
                                      'MNE',
                                                              'FRO',
              'KEN',
                                                      'MYT',
                                                                      'MMR',
                                                                              'PAN'
                     'LBY',
                              'MLI',
                                                              'BRB',
                                                                      'ABW',
                                      'NAM',
                                              'BOL',
                                                      'PRY',
             'BFA',
                                                                              'AIA'
                              'PYF',
                                      'GUY',
                                              'LCA',
             'SLV',
                     'DMA',
                                                      'ATA', 'GTM', 'ASM',
                                                                              'MRT',
             'NCL', 'KIR', 'SDN', 'ATF', 'SLE', 'LAO'], dtype=object)
[0]: np.unique(cat enc le)
[0]: array([
               0,
                           2,
                                 3,
                                      4,
                                            5,
                                                  6,
                                                        7,
                                                              8,
                                                                   9,
                                                                        10,
                                                                              11,
                                                                                    12,
                     1,
                          15,
                                                 19,
                                                       20,
               13,
                    14,
                                16,
                                     17,
                                           18,
                                                             21,
                                                                  22,
                                                                        23,
                                                                              24,
                                                                                    25,
                                29,
                    27,
                          28,
                                      30,
                                           31,
                                                 32,
                                                       33,
                                                             34,
                                                                  35,
                                                                        36,
                                                                              37,
               26,
                                                                                    38,
              39,
                    40,
                          41,
                                42,
                                     43,
                                           44,
                                                 45,
                                                       46,
                                                             47,
                                                                  48,
                                                                        49,
                                                                              50,
                    53,
                          54,
                                55,
                                      56,
                                           57,
                                                 58,
                                                       59,
                                                             60,
                                                                  61,
                                                                        62,
               52,
                                                                              63,
                                                                                    64,
                          67,
                                68,
                                     69,
                                           70,
                                                 71,
                                                       72,
                                                             73,
                                                                  74,
                                                                        75,
                                                                              76,
                                                                                    77,
               65,
                    66,
                                                       85,
                                                                        88,
                                                                                    90,
               78,
                    79,
                          80,
                                81,
                                     82,
                                           83,
                                                 84,
                                                             86,
                                                                  87,
                                                                              89,
                                                            99, 100, 101, 102, 103,
               91,
                    92,
                          93,
                                94,
                                     95,
                                           96,
                                                 97,
                                                       98,
             104, 105, 106, 107, 108, 109, 110, 111, 112, 113, 114, 115, 116,
             117, 118, 119, 120, 121, 122, 123, 124, 125, 126, 127, 128, 129,
             130, 131, 132, 133, 134, 135, 136, 137, 138, 139, 140, 141, 142,
             143, 144, 145, 146, 147, 148, 149, 150, 151, 152, 153, 154, 155,
             156, 157, 158, 159, 160, 161, 162, 163, 164, 165, 166, 167, 168,
             169, 170, 171, 172, 173, 174, 175, 176])
[0]: le.inverse_transform([0, 1, 2, 3])
[0]: array(['ABW', 'AGO', 'AIA', 'ALB'], dtype=object)
```

7. Кодирование категорий наборами бинарных значений

```
[0]: ohe = OneHotEncoder()
     cat enc ohe = ohe.fit_transform(data[['meal']])
[0]: data.shape
[0]: (119390, 32)
[0]: cat_enc_ohe.shape
[0]: (119390, 5)
[0]: cat_enc_ohe
[0]: <119390x5 sparse matrix of type '<class 'numpy.float64'>'
             with 119390 stored elements in Compressed Sparse Row format>
[0]: cat_enc_ohe.todense()[0:10]
[0]: matrix([[1., 0., 0., 0., 0.],
             [1., 0., 0., 0., 0.]
             [1., 0., 0., 0., 0.]
             [1., 0., 0., 0., 0.]
             [1., 0., 0., 0., 0.]
             [1., 0., 0., 0., 0.]
             [1., 0., 0., 0., 0.]
             [0., 1., 0., 0., 0.]
             [1., 0., 0., 0., 0.]
             [0., 0., 1., 0., 0.]
[0]: cat enc.head(10)
[0]:
        c1
       PRT
    0
    1 PRT
     2 GBR
     3 GBR
    4 GBR
    5 GBR
    6 PRT
    7 PRT
    8 PRT
    9 PRT
[0]: cat enc ohe = ohe.fit transform(data[['market segment']])
[0]: cat enc ohe.shape
[0]: (119390, 8)
[0]: cat enc ohe
```

[0., 0., 0., 0., 0., 1., 0., 0.]]

8. Pandas get dummies

```
[0]: pd.get dummies(cat enc).head()
[0]:
         c1 ABW
                  c1_AGO
                           c1_AIA
                                     c1 ALB
                                                  c1_VNM
                                                           c1_ZAF
                                                                     c1 ZMB
                                                                              c1 ZWE
                                              ...
     0
               0
                        0
                                  0
                                           0
                                                                 0
                                                                                    0
                                                        0
                                              ...
     1
               0
                        0
                                  0
                                           0
                                                        0
                                                                 0
                                                                           0
                                                                                    0
     2
               0
                        0
                                  0
                                           0
                                                        0
                                                                 0
                                                                           0
                                                                                    0
     3
               0
                        0
                                  0
                                           0
                                                        0
                                                                 0
                                                                           0
                                                                                    0
     4
               0
                        0
                                  0
                                                                 0
                                                                           0
                                                                                    0
     [5 rows x 177 columns]
```

[0]: pd.get_dummies(cat_temp_data, dummy_na=True).head()

```
[0]:
        country_ABW
                      country_AGO country_AIA ... country_ZMB
                                                                      country ZWE
     country_nan
     0
                    0
                                  0
                                                 0
                                                                   0
                                                                                 0
     0
     1
                    0
                                  0
                                                                                 0
     0
     2
                    0
                                  0
                                                                                 0
     0
     3
                    0
                                  0
                                                                                 0
     0
     4
                                                 0 ...
                    0
                                  0
                                                                   0
                                                                                 0
```

[5 rows x 178 columns]

9. Масштабирование данных

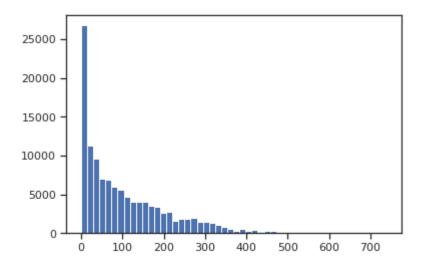
[0]: **from sklearn.preprocessing import** MinMaxScaler, StandardScaler,

→Normalizer

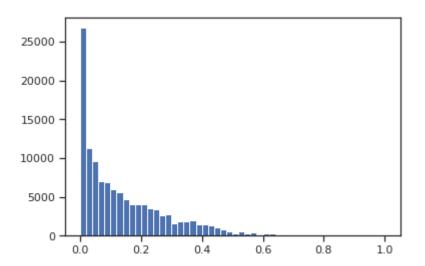
10. MinMax

```
[0]: sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data[['lead_time']])
```

```
[0]: plt.hist(data['lead_time'], 50)
plt.show()
```



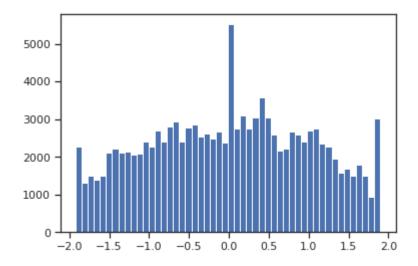
```
[0]: plt.hist(sc1_data, 50)
plt.show()
```



11. Z-оценка

```
[0]: sc2 = StandardScaler()
sc2_data = sc2.fit_transform(data[['arrival_date_week_number']])
```

```
[0]: plt.hist(sc2_data, 50)
plt.show()
```



12. Нормализация

```
[0]: sc3 = Normalizer()
sc3_data = sc3.fit_transform(data[['booking_changes']])
```

```
[0]: plt.hist(sc3_data, 50)
plt.show()
```

