# Московский государственный технический университет им. Н.Э. Баумана Кафедра «Системы обработки информации и управления»

# Лабораторная работа №6 по дисциплине «Методы машинного обучения» на тему «Ансамбли моделей машинного обучения»

Выполнил: студент группы ИУ5-23М Наседкин И. А.

# 1. Ансамбли моделей машинного обучения

Цель лабораторной работы: изучение ансамблей моделей машинного обучения. Задание:

- 1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train test split разделите выборку на обучающую и тестовую.
- 4. Обучите две ансамблевые модели. Оцените качество моделей с помощью одной из подходящих для задачи метрик. Сравните качество полученных моделей.
- 5. Произведите для каждой модели подбор значений одного гиперпараметра. В зависимости от используемой библиотеки можно применять функцию GridSearchCV, использовать перебор параметров в цикле, или использовать другие методы.
- 6. Повторите пункт 4 для найденных оптимальных значений гиперпараметров. Сравните качество полученных моделей с качеством моделей, полученных в пункте 4.
- 1. Подготовка данных; датасет https://www.kaggle.com/ronitf/heart-disease-uci/version/1
- 2. age;—возраст;
- 3. sex;—пол;
- 4. chest pain type (4 values);—Тип боли;
- 5. resting blood pressure;—Кровяное давление в покое;
- 6. serum cholestoral in mg/dl;—Холестерин;
- 7. fasting blood sugar > 120 mg/dl;—Сахар в крови;
- 8. resting electrocardiographic results (values 0,1,2);—Электрокардиография в покое;
- 9. maximum heart rate achieved;—Максимальный сердечный ритм;
- 10. exercise induced angina;—Стенокардия вызванная физической нагрузкой;
- 11. oldpeak = ST depression induced by exercise relative to rest;—депрессия вызванная физ упражнениями;
- 12. the slope of the peak exercise ST segment;—Наклон пика упражнений;
- 13. number of major vessels (0-3) colored by flourosopy;—Кол-во крупных сосоудов по цвету thal: 3 = normal; 6 = fixed defect; 7 = reversable defect;

```
[1]: import numpy as np
  import pandas as pd
  import seaborn as sns
  import matplotlib.pyplot as plt
  %matplotlib inline
  sns.set(style="ticks")
```

/usr/local/lib/python3.6/dist-packages/statsmodels/tools/\_testing.py:19:
FutureWarning: pandas.util.testing is deprecated. Use the functions in 

→ the

public API at pandas.testing instead.
 import pandas.util.testing as tm

```
[0]: data = pd.read_csv('heart.csv')
[3]: data.head()
```

```
age sex cp trestbps chol fbs ... exang oldpeak slope
[3]:
                                                                         ca
                                                                             thal
     target
                    3
                            145
                                   233
                                                     0
                                                            2.3
                                                                      0
                                                                          0
     0
         63
               1
                                          1
                                                                                 1
     1
     1
         37
                    2
                            130
                                                            3.5
                                                                      0
                                                                                 2
               1
                                   250
                                                     0
                                                                          0
                                          0
     1
     2
                    1
                            130
                                                                      2
                                                                                 2
         41
               0
                                   204
                                                     0
                                                            1.4
                                                                          0
                                          0
     1
     3
         56
               1
                    1
                            120
                                   236
                                          0
                                                     0
                                                            0.8
                                                                      2
                                                                          0
                                                                                 2
     1
     4
                                          0 ...
                                                            0.6
                                                                      2
                                                                          0
                                                                                 2
         57
               0
                    0
                            120
                                   354
                                                     1
     1
```

[5 rows x 14 columns]

```
[4]: data.shape
```

[4]: (303, 14)

```
[5]: data.isnull().sum()
```

```
0
[5]: age
     sex
                  0
     ср
                  0
     trestbps
                  0
     chol
                  0
     fbs
                  0
     restecg
                  0
     thalach
                  0
     exang
                  0
     oldpeak
                  0
     slope
                  0
     ca
                  0
     thal
                  0
                  0
     target
     dtype: int64
```

Датасет без пустых значений

## 1.0.1. Feature Scaling

```
[6]: from sklearn.preprocessing import MinMaxScaler
import warnings

from sklearn import svm
from sklearn.neighbors import KNeighborsClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import roc_curve, auc
import pylab as pl
import matplotlib.pyplot as plt
```

```
warnings.filterwarnings('ignore')

# Create the scaler object with a range of 0-1
scaler = MinMaxScaler(feature_range=(0, 1))
# Fit on data, transform data
scaler.fit_transform(data)
```

```
[6]: array([[0.70833333, 1.
                                , 1.
                                           , ..., 0.
                                                          , 0.33333333,
            1.
                                 , 0.66666667, ..., 0.
                                                          , 0.66666667,
           [0.16666667, 1.
           1.
                     ],
                                 , 0.33333333, ..., 0.
           [0.25
                     , 0.
                                                          , 0.66666667,
            1.
                     ],
           [0.8125 , 1.
                                 , 0. , ..., 0.5 , 1.
           0.
                                 , 0.
           [0.58333333, 1.
                                        , ..., 0.25
                                                          , 1.
           [0.58333333, 0.
                                 , 0.33333333, ..., 0.25
                                                          , 0.66666667,
            0.
                     11)
```

Разделим датасет на тестовую и обучающую выборки

```
[0]: X = data.drop('target',axis = 1).values
y = data['target'].values
```

### 1.0.2. Ансамблевые модели

```
[0]: from sklearn.model_selection import train_test_split
    from sklearn.model_selection import cross_val_score
    from sklearn.ensemble import ExtraTreesClassifier, ExtraTreesRegressor

    from sklearn.ensemble import RandomForestClassifier, AdaBoostClassifier
    from sklearn.metrics import accuracy_score
    from sklearn.metrics import balanced_accuracy_score
    from sklearn.metrics import precision_score, recall_score, f1_score

    from sklearn.model_selection import GridSearchCV
```

- [0]: kfold = 5 #количество подвыборок для валидации
- [0]: itog\_val = {} #список для записи результатов кросс валидации разных№ →алгоритмов
- [0]: ROCtrainTRN, ROCtestTRN, ROCtrainTRG, ROCtestTRG = train\_test\_split(X, → y, test\_size=0.20)
- [0]: model\_rfc = RandomForestClassifier(n\_estimators = 75) #6 параметре⊡


  →передаем кол-во деревьев

```
model_knc = KNeighborsClassifier(n_neighbors = 20) #6 параметре → передаем кол-во соседей model_lr = LogisticRegression(penalty='l2', tol=0.01) #11 model_svc = svm.SVC() #по умолчанию kernel='rbf'
```

- 1. SVM метод опорных векторов(SVC)
- 2. Метод k-ближайших соседей(KNeighborsClassifier)
- 3. Случайный лес(RandomForestClassifier)
- 4. Логистическая регрессия (LogisticRegression)

```
[0]: scores = cross_val_score(model_rfc, X, y, cv = kfold)
   itog_val['RandomForestClassifier'] = scores.mean()
   scores = cross_val_score(model_knc, X, y, cv = kfold)
   itog_val['KNeighborsClassifier'] = scores.mean()
   scores = cross_val_score(model_lr, X, y, cv = kfold)
   itog_val['LogisticRegression'] = scores.mean()
   scores = cross_val_score(model_svc, X, y, cv = kfold)
   itog_val['SVC'] = scores.mean()
```


[14]: <matplotlib.axes.\_subplots.AxesSubplot at 0x7f5d112094a8>



```
[15]: pl.clf()
plt.figure(figsize=(8,6))
```

```
#SVC
model svc.probability = True
probas = model svc.fit(ROCtrainTRN, ROCtrainTRG).
 →predict proba(ROCtestTRN)
fpr, tpr, thresholds = roc_curve(ROCtestTRG, probas[:, 1])
roc auc = auc(fpr, tpr)
pl.plot(fpr, tpr, label='%s ROC (area = %0.2f)' % ('SVC', roc auc))
#RandomForestClassifier
probas = model rfc.fit(ROCtrainTRN, ROCtrainTRG).
 →predict_proba(ROCtestTRN)
fpr, tpr, thresholds = roc curve(ROCtestTRG, probas[:, 1])
roc auc = auc(fpr, tpr)
pl.plot(fpr, tpr, label='%s ROC (area = %0.2f)' %
 →('RandonForest',roc_auc))
#KNeighborsClassifier
probas = model knc.fit(ROCtrainTRN, ROCtrainTRG).
 →predict_proba(ROCtestTRN)
fpr, tpr, thresholds = roc curve(ROCtestTRG, probas[:, 1])
roc auc = auc(fpr, tpr)
pl.plot(fpr, tpr, label='%s ROC (area = %0.2f)' %
 #LogisticRegression
probas = model lr.fit(ROCtrainTRN, ROCtrainTRG).
 →predict proba(ROCtestTRN)
fpr, tpr, thresholds = roc_curve(ROCtestTRG, probas[:, 1])
roc auc = auc(fpr, tpr)
pl.plot(fpr, tpr, label='%s ROC (area = %0.2f)' %
 pl.plot([0, 1], [0, 1], 'k--')
pl.xlim([-0.1, 1.1])
pl.ylim([-0.1, 1.1])
pl.xlabel('False Positive Rate')
pl.ylabel('True Positive Rate')
pl.legend(loc=0, fontsize='small')
pl.show()
```

<Figure size 432x288 with 0 Axes>



```
[0]: # Функция train_test_split разделила исходную выборку таким образом, #чтобы в обучающей и тестовой частях сохранились пропорции классов.

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.35, random_state=1)
```

```
[17]: from sklearn.preprocessing import MinMaxScaler
warnings.filterwarnings('ignore')

# Create the scaler object with a range of 0-1
scaler = MinMaxScaler(feature_range=(0, 1))
# Fit on data, transform data
scaler.fit_transform(X)
scaler.fit_transform(X_train)
scaler.fit_transform(X_test)
```

```
[17]: array([[0.7777778, 0.
                                        , 0.
                                                                      , 0.75
                                                      , ..., 0.
               1.
              [0.61111111, 1.
                                        , 0.33333333, ..., 1.
                                                                       , 0.
              [0.3888889, 1.
                                                                       , 0.5
               1.
                           ],
              [0.52777778, 1.
                                        , 0.
                                                      , ..., 0.
                                                                       , 0.
              [0.6666667, 1.
                                        , 0.33333333, ..., 0.5
                                                                       , 1.
              [0.3888889, 1.
                                        , 0.33333333, ..., 0.
                                                                       , 0.
               1.
                          ]])
```

```
[0]: rfc = RandomForestClassifier().fit(X train, y train)
      predicted_rfc = rfc.predict(X_test)
[19]: accuracy_score(y_test, predicted_rfc)
[19]: 0.7476635514018691
[20]: balanced accuracy score(y test, predicted rfc)
[20]: 0.7484210526315789
[21]: (precision score(y test, predicted rfc, average='weighted'),
       recall_score(y_test, predicted_rfc, average='weighted'))
[21]: (0.7493681302533357, 0.7476635514018691)
[22]: f1_score(y_test, predicted_rfc, average='weighted')
[22]: 0.7479284020432736
[0]: abc = AdaBoostClassifier().fit(X train, y train)
      predicted abc = abc.predict(X test)
[24]: accuracy_score(y_test, predicted_abc)
[24]: 0.7289719626168224
[25]: balanced_accuracy_score(y_test, predicted_abc)
[25]: 0.7284210526315789
[26]: (precision_score(y_test, predicted_abc, average='weighted'),
       recall score(y test, predicted abc, average='weighted'))
[26]: (0.7293842770753162, 0.7289719626168224)
[27]: f1_score(y_test, predicted_abc, average='weighted')
[27]: 0.7291144464706996
[28]: rfc_n_range = np.array(range(5,100,5))
      rfc tuned parameters = [{'n estimators': rfc n range}]
      rfc tuned parameters
[28]: [{'n_estimators': array([ 5, 10, 15, 20, 25, 30, 35, 40, 45, 50, 55, 12]
       60, 65, 70,
     75, 80, 85,
               90, 95])}]
[29]: warnings.filterwarnings('ignore')
      gs rfc = GridSearchCV(RandomForestClassifier(), rfc tuned parameters, ₽
       \hookrightarrow CV=5,
```

```
gs_rfc.fit(X_train, y_train)
[29]: GridSearchCV(cv=5, error_score=nan,
                                                              estimator=RandomForestClassifier(bootstrap=True, Page 1971)

¬ccp alpha=0.0,
                                                                                                                                                                             class_weight=None,
                                                                                                                                                                             criterion='gini',₽
                        →max depth=None,
                                                                                                                                                                             max features='auto',
                                                                                                                                                                             max_leaf_nodes=None,
                                                                                                                                                                             max samples=None,
                                                                                                                                                                             min_impurity_decrease=0.0,
                                                                                                                                                                             min impurity split=None,
                                                                                                                                                                             min samples leaf=1,
                                                                                                                                                                             min samples split=2,
                        →min weight fraction leaf=0.0,
                                                                                                                                                                             n_estimators=100,₽
                        →n jobs=None,
                                                                                                                                                                             oob score=False,
                                                                                                                                                                             random_state=None, <a>₽</a>
                        →verbose=0,
                                                                                                                                                                             warm start=False),
                                                              iid='deprecated', n jobs=None,
                                                              param_grid=[{'n_estimators': array([ 5, 10, 15, 20, 25, Param_grid=[{'n_estimators': a
                        \rightarrow 30, 35, 40,
                   45, 50, 55, 60, 65, 70, 75, 80, 85,
                                           90, 95])}],
                                                              pre_dispatch='2*n_jobs', refit=True,P
                        →return_train_score=False,
                                                              scoring='accuracy', verbose=0)
[30]: gs_rfc.best_params_
[30]: {'n estimators': 25}
[31]: plt.plot(rfc_n_range, gs_rfc.cv_results_['mean_test_score'])
[31]: [<matplotlib.lines.Line2D at 0x7f5d10b90828>]
```

scoring='accuracy')

```
0.88

0.87

0.86

0.85


0.84

0.83

0.82

20 40 60 80
```

```
[32]: abc_n_range = np.array(range(5,100,5))
      abc_tuned_parameters = [{'n_estimators': abc_n_range}]
      abc_tuned_parameters
[32]: [{'n_estimators': array([ 5, 10, 15, 20, 25, 30, 35, 40, 45, 50, 55, 12]
       →60, 65, 70,
      75, 80, 85,
               90, 95])}]
[33]: gs_abc = GridSearchCV(AdaBoostClassifier(), abc_tuned_parameters, cv=5,
                            scoring='accuracy')
      gs_abc.fit(X_train, y_train)
[33]: GridSearchCV(cv=5, error_score=nan,
                   estimator=AdaBoostClassifier(algorithm='SAMME.R',
                                                 base_estimator=None,
                                                 learning_rate=1.0,₽
       →n estimators=50,
                                                 random state=None),
                   iid='deprecated', n_jobs=None,
                   param_grid=[{'n_estimators': array([ 5, 10, 15, 20, 25, №
       \rightarrow 30, 35, 40,
     45, 50, 55, 60, 65, 70, 75, 80, 85,
             90, 95])}],
                   pre_dispatch='2*n_jobs', refit=True,P
       →return_train_score=False,
                   scoring='accuracy', verbose=0)
[34]: gs_abc.best_params_
[34]: {'n estimators': 25}
[35]: plt.plot(abc_n_range, gs_abc.cv_results_['mean_test_score'])
[35]: [<matplotlib.lines.Line2D at 0x7f5d10b16f28>]
```



```
[0]: rfc_optimized = RandomForestClassifier(n_estimators=gs_rfc.
       →best_params_['n_estimators']).fit(X_train, y_train)
      predicted_rfc_opt = rfc_optimized.predict(X_test)
[37]: accuracy_score(y_test, predicted_rfc_opt)
[37]: 0.7009345794392523
[38]: balanced_accuracy_score(y_test, predicted_rfc_opt)
[38]: 0.6984210526315789
[39]: (precision_score(y_test, predicted_rfc_opt, average='weighted'),
       recall_score(y_test, predicted_rfc_opt, average='weighted'))
[39]: (0.7004791699667353, 0.7009345794392523)
[40]: f1_score(y_test, predicted_rfc_opt, average='weighted')
[40]: 0.7004610416515945
[0]: abc optimized = RandomForestClassifier(n estimators=gs abc.
       →best_params_['n_estimators']).fit(X_train, y_train)
      predicted_abc_opt = abc_optimized.predict(X_test)
[42]: accuracy_score(y_test, predicted_abc_opt)
[42]: 0.7383177570093458
[43]: balanced_accuracy_score(y_test, predicted_abc_opt)
[43]: 0.7371929824561403
[44]: (precision_score(y_test, predicted_abc_opt, average='weighted'),
       recall_score(y_test, predicted_abc_opt, average='weighted'))
```

```
[44]: (0.7383177570093458, 0.7383177570093458)

[45]: f1_score(y_test, predicted_abc_opt, average='weighted')

[45]: 0.7383177570093458

Результаты для разных методов примерно одинаковые.

[0]:
```